Gulherme Lage e Vítor Stahlberg

Objetivos do relatório

O objetivo deste laboratório é estudar as principais características de sistemas open-source populares, focando em métricas que podem revelar aspectos importantes sobre o desenvolvimento desses projetos. Especificamente, buscamos analisar:

- RQ 01: Verificar se sistemas populares são maduros/antigos, analisando a idade dos repositórios.
- RQ 02: Examinar se sistemas populares recebem muita contribuição externa, medindo o total de pull requests aceitas.
- RQ 03: Analisar a frequência de lançamentos de releases em sistemas populares, calculando o total de releases.
- RQ 04: Avaliar a frequência de atualizações em sistemas populares, verificando o tempo desde a última atualização.
- RQ 05: Identificar se os sistemas populares são escritos nas linguagens mais populares, analisando a linguagem primária
- de cada repositório.
- RQ 06: Estudar o percentual de issues fechadas nos sistemas populares, calculando a razão entre o número de issues fechadas e o total de issues.
- RQ 07: Investigar se sistemas escritos nas linguagens mais populares recebem mais contribuição externa, lançam mais releases e são atualizados com mais frequência.

Metodologia

A metodologia adotada para responder às questões de pesquisa será baseada na coleta de dados dos 1.000 repositórios mais populares do GitHub, utilizando a API GraphQL do GitHub. O processo será dividido em duas etapas:

1. Coleta de Dados

A coleta de dados será realizada por uma consulta GraphQL personalizada para obter informações sobre os 1.000 repositórios mais populares no GitHub. Para isso, será necessário:

- Consulta GraphQL: Desenvolver uma consulta para buscar informações sobre o nome do repositório, número de estrelas, proprietário, datas de criação e atualização, linguagem principal, quantidade de pull requests abertos e mesclados, número de releases e issues abertas e fechadas.
- Paginação: Para coletar dados de todos os 1.000 repositórios, implementaremos a funcionalidade de paginação na consulta GraphQL.
- Armazenamento em CSV: Os dados serão armazenados num arquivo .csv para facilitar a análise posterior.

2. Análise dos Dados

Após a coleta dos dados, será realizada a análise para responder às questões de pesquisa:

- Análise Quantitativa: Será calculado o valor médio ou mediano das métricas para cada questão de pesquisa (RQ), como idade do repositório, número de pull requests, total de releases, e outros. Essas métricas serão comparadas entre diferentes repositórios e linguagens.
- Análise Qualitativa: Para as métricas de categoria, como a linguagem primária dos repositórios, será realizada uma contagem para identificar quais linguagens são mais comuns entre os repositórios populares.

Resultados obtidos

RQ-01: Sistemas populares são maduros/antigos?

Com base nos dados obtidos, analisamos a data de criação de cada repositório para quantificar quantos foram criados a cada ano desde 2008, ano de fundação do GitHub. A partir dessa análise, calculamos a média ponderada da idade dos repositórios, utilizando a fórmula: `(quantidade de repositórios no ano x idade do repositório) / quantidade total de repositórios` . Como resultado, verificamos que a idade média dos repositórios é de 8,6 anos, o que indica que, de fato, os repositórios mais populares são, em sua maioria, maduros e possuem uma longa trajetória de desenvolvimento.

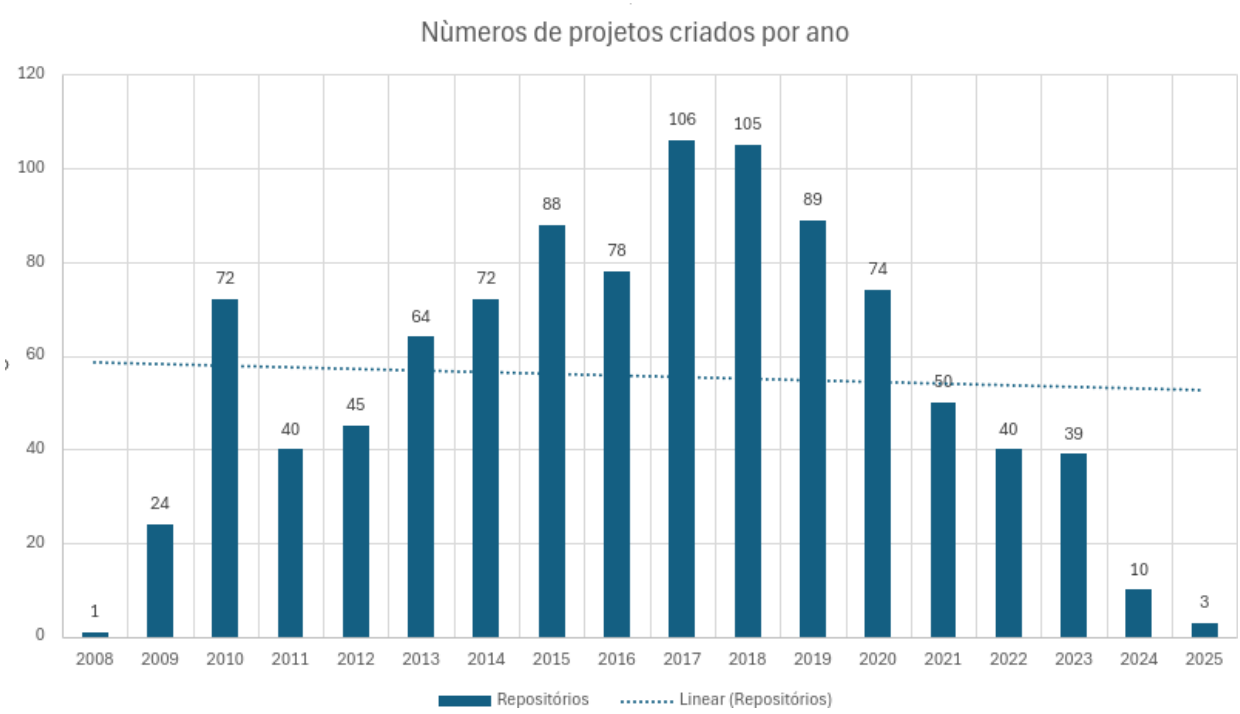

RQ-02: Sistemas populares recebem muita contribuição externa?

Para avaliar se sistemas populares recebem mais contribuições externas, analisamos a quantidade total de pull requests (PRs) aceitos nos repositórios. Em nossa análise inicial, observamos que o número de contribuições aumentava gradualmente à medida que o repositório crescia.

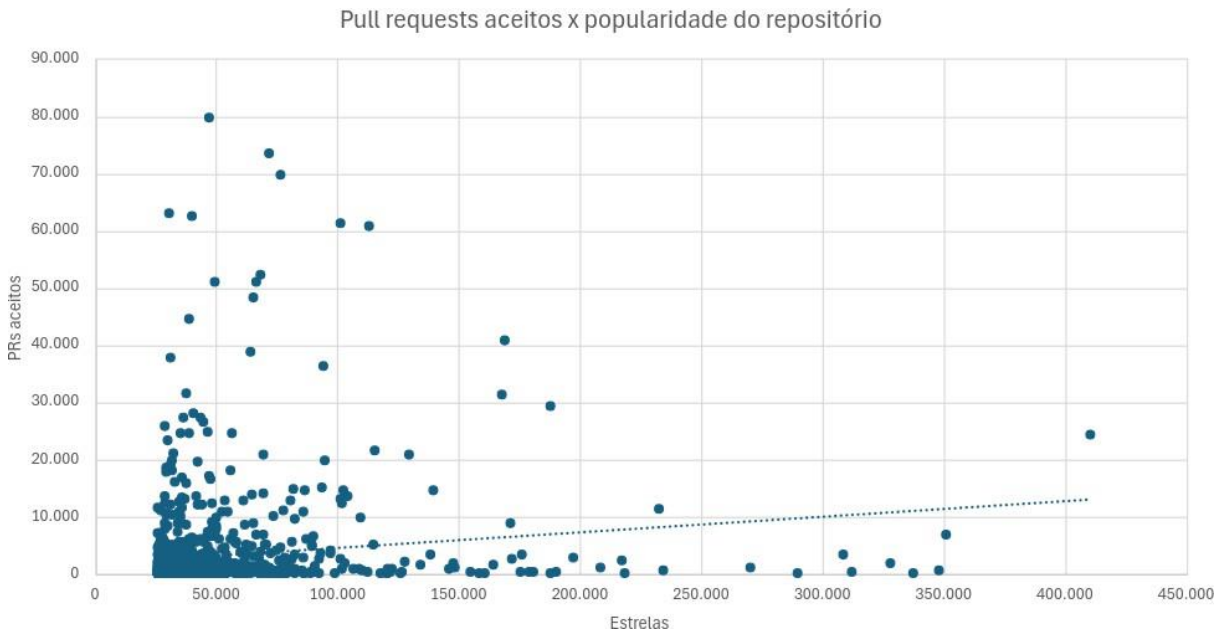

Em um estudo posterior, identificamos a presença de vários outliers em nossa amostra (valores que distorciam ou tendenciavam os resultados). Com isso, decidimos realizar uma nova análise, excluindo os outliers (repositórios com números de PRs aceitos significativamente acima ou abaixo da média). Na segunda análise, os dados corroboraram as conclusões da primeira: o número de contribuições aumentava conforme o repositório crescia, porém de forma menos acentuada. Isso sugere que, ao remover os outliers, a popularidade do repositório exerce menor influência no número de contribuições externas do que inicialmente parecia.

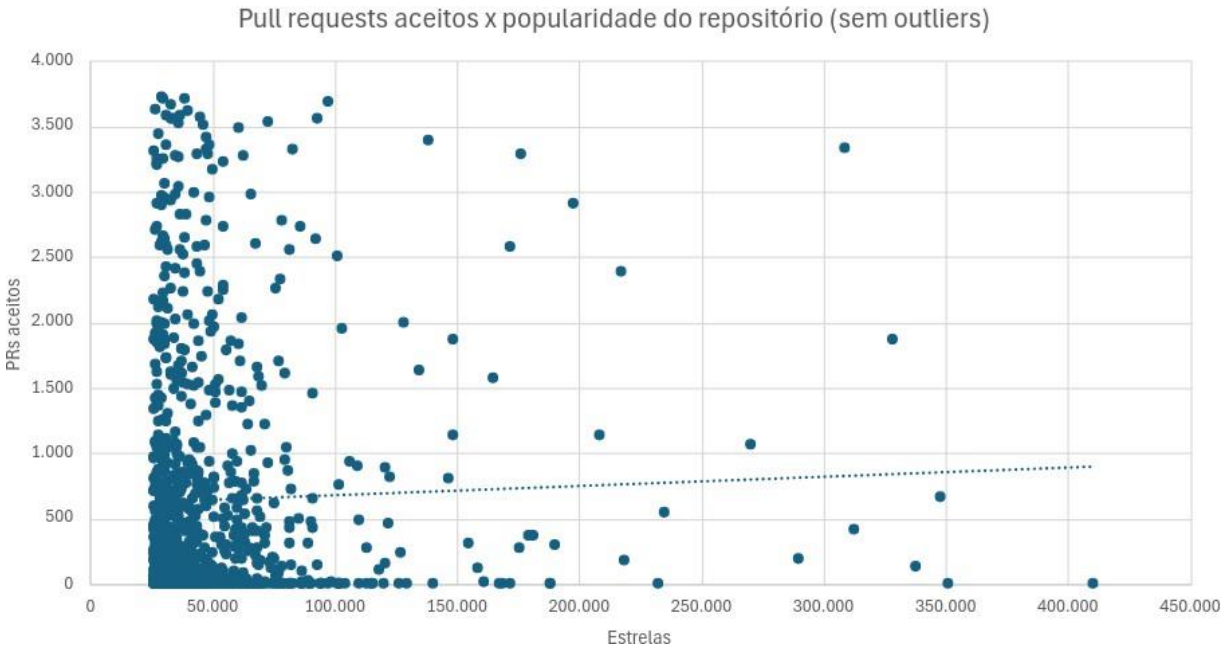

RQ-03: Sistemas populares lançam releases com frequência?

Em nossa análise inicial, observamos que o número de releases não aumentava necessariamente de acordo com a popularidade do repositório, mantendo-se relativamente estável à medida que a popularidade crescia.

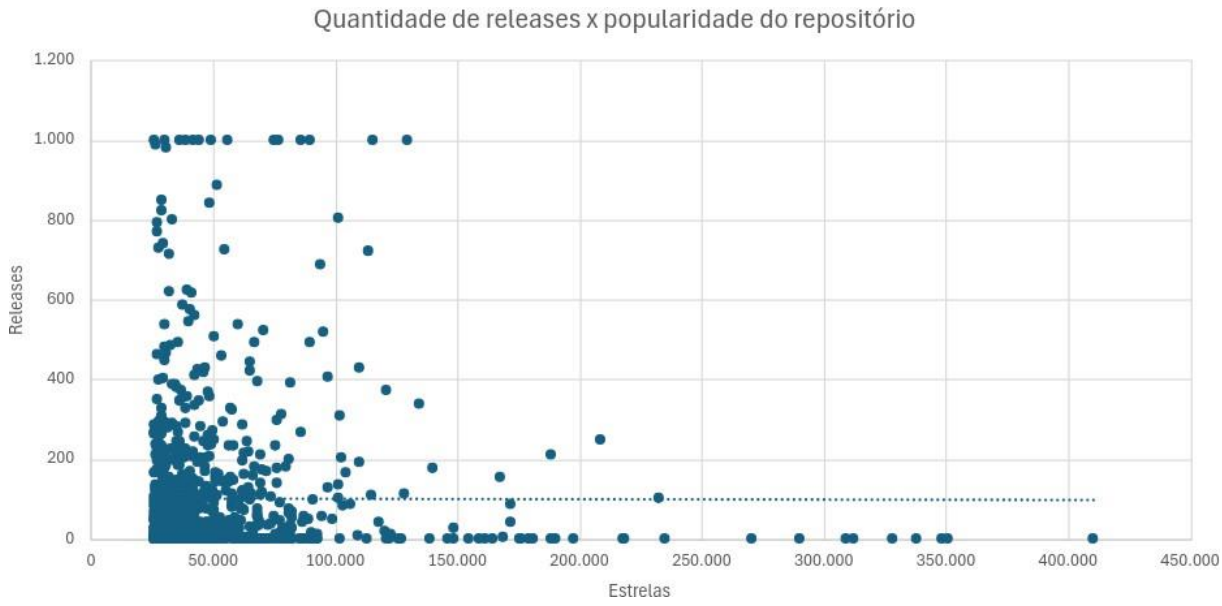

No entanto, ao removermos os valores que poderiam distorcer a análise (outliers), constatamos que o número de releases, na verdade, diminuía à medida que a popularidade dos repositórios aumentava. Foi mais comum encontrar projetos sem releases entre os mais populares do que entre os menos populares. É importante destacar, contudo, que a quantidade de releases é medida com base nas publicações de releases na ferramenta do GitHub. Ou seja, se um repositório não utiliza essa funcionalidade para lançar suas releases, os dados não refletem a realidade do projeto nesta análise e por consequência distorce o resultado.

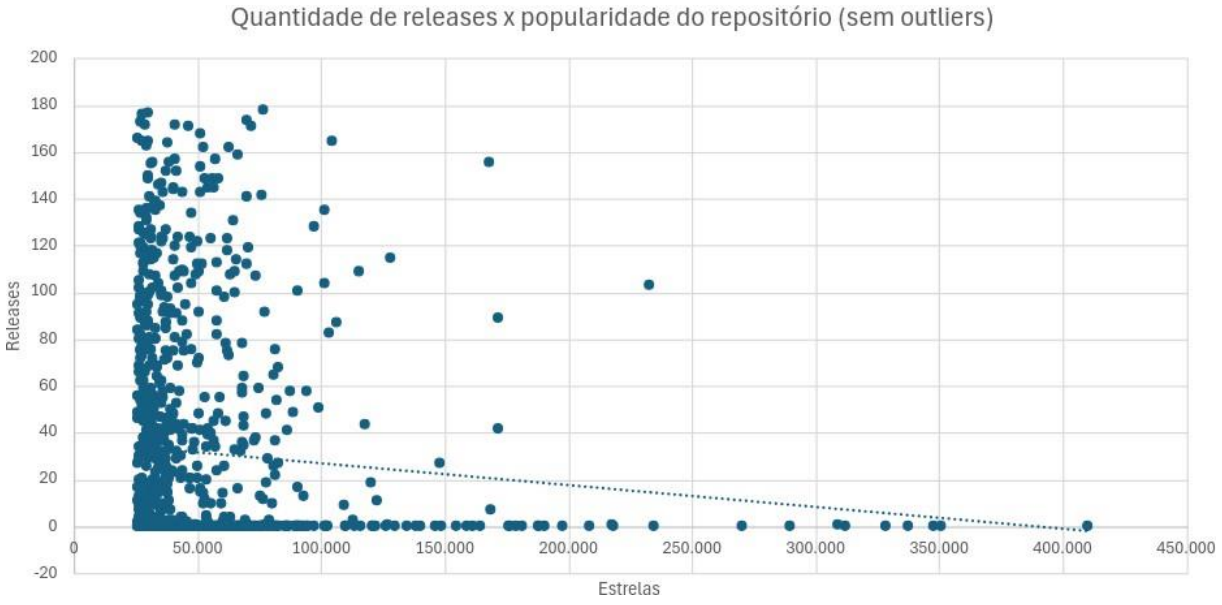

RQ-04: Sistemas populares são atualizados com frequência?

Não foram observadas diferenças significativas entre os repositórios no que diz respeito à frequência de atualizações. A pesquisa foi realizada no dia 20 de fevereiro de 2025, e 993 dos 1.000 repositórios buscados haviam sido atualizados nesse mesmo dia. Apenas 7 repositórios tinham sido atualizados no dia anterior (19 de fevereiro de 2025), o que sugere uma frequência bastante alta de atualizações nos repositórios como um todo.

RQ-05: Sistemas populares são escritos nas linguagens mais populares?

As linguagens mais populares, de acordo com o Octaverse, são JavaScript, Python, Java, TypeScript e C#. Com exceção do C#, todas as outras linguagens estão entre as mais utilizadas nos repositórios analisados, o que indica que a maioria dos repositórios populares está escrita nas linguagens mais comuns no ecossistema de desenvolvimento.

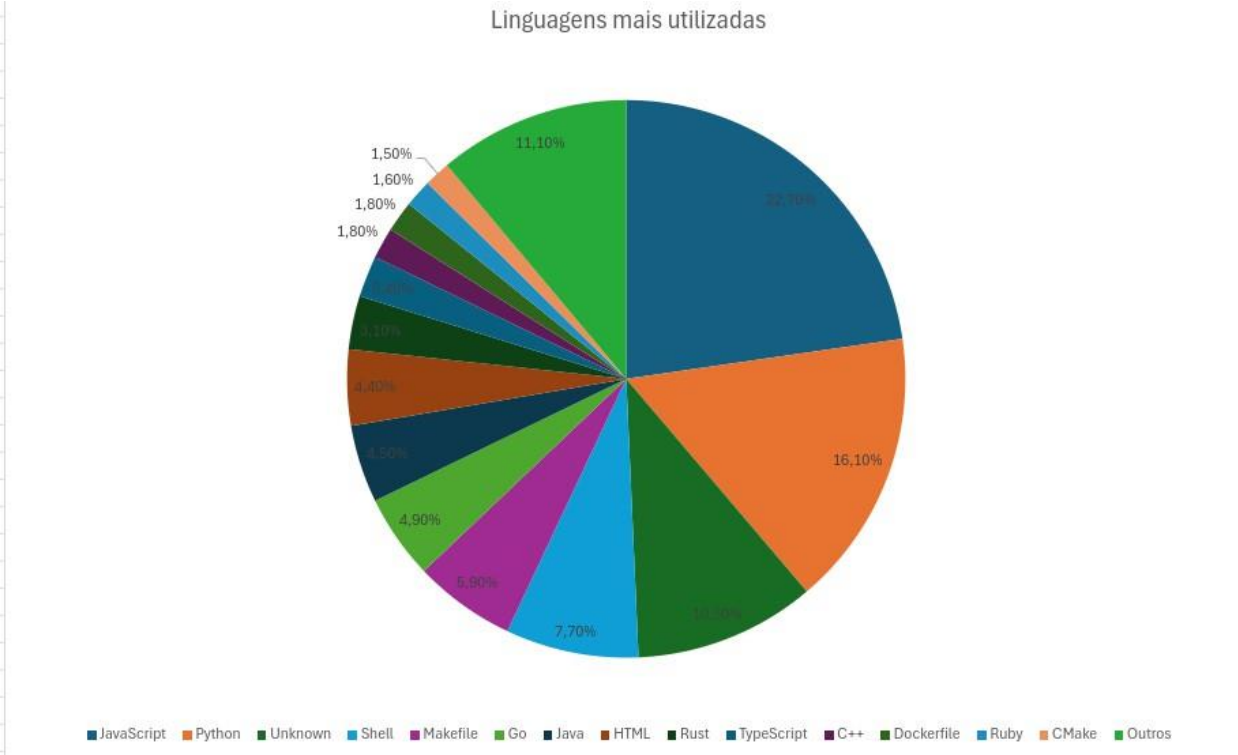

RQ-06: Sistemas populares possuem um alto percentual de issues fechadas?

Preliminarmente, os repositórios mais populares aparentam ter um percentual maior de issues fechadas do que repositórios menores como pode-se ver no gráfico a seguir.

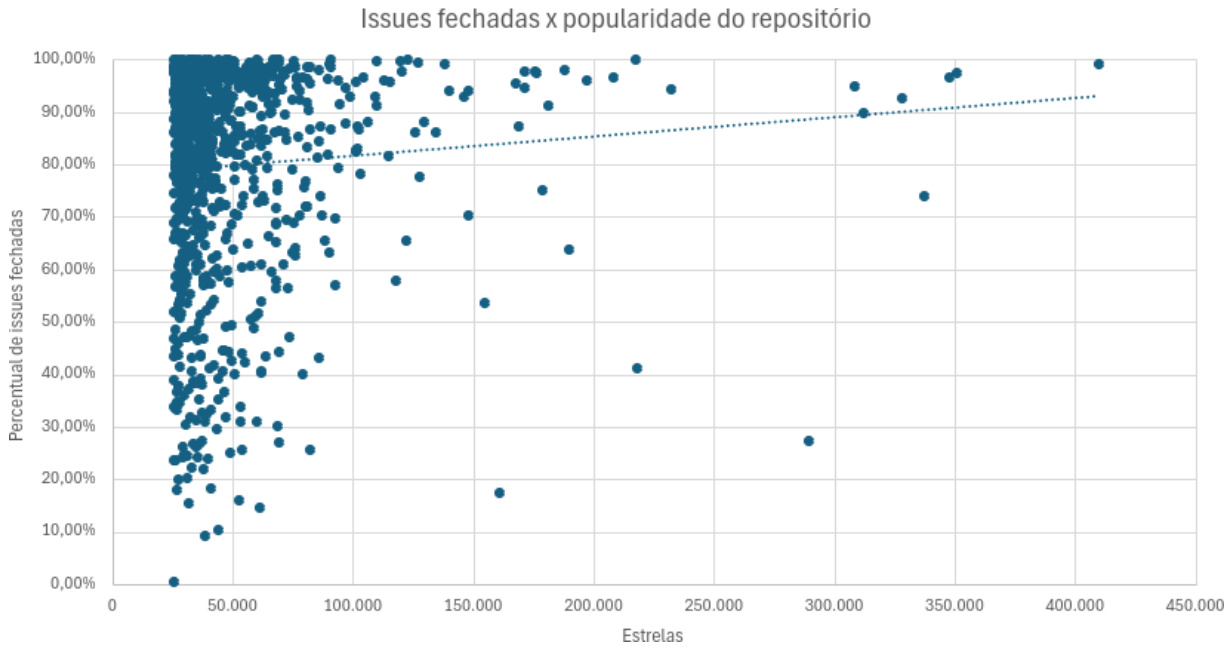

Esta análise é também complementada com a verificação de outliers, que, ao serem desconsiderados, comfirmam o mesmo resultado obtido considerando-os. As diferenças entre as duas análises são mínimas devido ao número considerado para outliers ser acima de 100%, que não ocorre nessa situação. Por isso, a maior diferença analisada é que alguns projetos com menos de 20% de isues fechadas foram considerados outliers e removidos do gráfico.

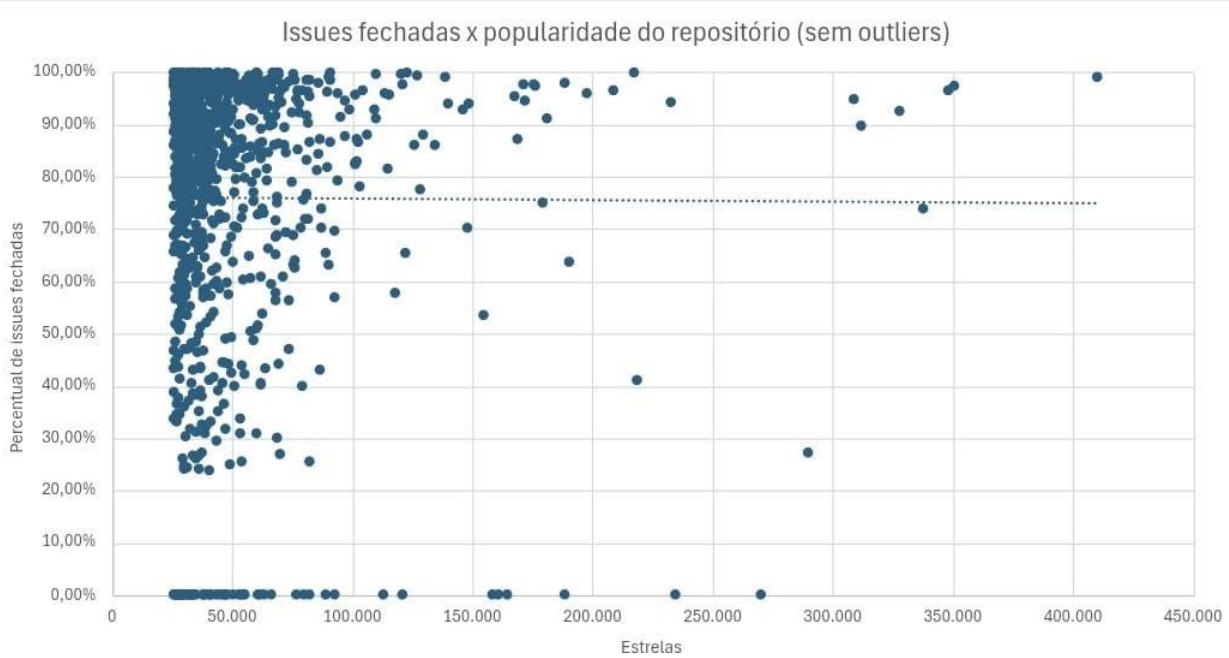

RQ-07: Sistemas escritos em linguagens mais populares recebem mais contribuição externa, lançam mais releases e são atualizados com mais frequência?

Com base nas análises realizadas nos outros itens, podemos investigar se existe uma relação entre a linguagem usada nos repositórios e três fatores principais: a contribuição externa, a frequência de releases e a frequência de atualizações.

Contribuição Externa:

Observamos que a quantidade de pull requests aceitos aumentava à medida que o repositório crescia, mas com a remoção dos outliers, foi possível verificar que a popularidade do repositório (relacionada à linguagem) tem uma influência moderada nas contribuições externas. A linguagem, por si só, não foi um fator determinante para o aumento das contribuições externas. Contudo, os repositórios escritos em linguagens mais populares (como JavaScript, Python e TypeScript) tendem a ter uma base de usuários maior, o que pode, de forma indireta, resultar em mais contribuições externas.

Lançamento de Releases:

A análise do número de releases mostrou que, ao remover os outliers, o número de releases não aumentava necessariamente com a popularidade do repositório. No entanto, projetos populares, especialmente os que utilizam linguagens como JavaScript e Python, mostraram-se menos dependentes da funcionalidade de releases do GitHub. Alguns repositórios podem optar por outras formas de entrega, como versões contínuas ou dependências gerenciadas externamente, o que pode distorcer a análise de releases diretamente no GitHub.

Frequência de Atualizações:

A frequência de atualizações, em geral, foi muito alta para todos os repositórios, com 993 dos 1.000 repositórios atualizados no mesmo dia da coleta. Essa alta frequência de atualizações não parece estar fortemente correlacionada com a linguagem de programação, indicando que a prática de manter os repositórios atualizados é comum, independentemente da linguagem usada. Isso sugere que a rapidez nas atualizações é mais um reflexo de boas práticas de manutenção do projeto do que da linguagem específica.

Os repositórios escritos em linguagens mais populares, como JavaScript, Python e TypeScript, tendem a atrair mais contribuições externas devido à sua base de usuários maior, mas a relação com o número de releases e a frequência de atualizações não é tão clara. A frequência de releases não está necessariamente relacionada com a popularidade da linguagem, e a manutenção de atualizações é uma prática comum em todos os repositórios, independentemente da linguagem de programação utilizada.